

# Консольный анализатор логов веб-сервера (Log Analyzer)

## 1. Введение

Веб-серверы (такие как Nginx или Apache) записывают информацию о каждом входящем запросе в файлы логов (обычно access.log). Анализ этих данных помогает выявлять подозрительную активность (DDoS-атаки), находить битые ссылки (ошибки 404) и понимать, какие страницы сайта наиболее популярны.

**Цель:** Разработать скрипт, который считывает лог-файл, обрабатывает его содержимое и выводит аналитическую сводку в консоль.

## 2. Требования к функционалу (Спецификация)

Программа должна обработать файл access.log и вывести в консоль три блока данных:

### 1. Топ-5 активных IP-адресов:

- Скрипт должен подсчитать количество запросов с каждого уникального IP-адреса.
- Вывести топ-5 IP-адресов по убыванию количества запросов в формате: IP-адрес: <кол-во запросов>.

### 2. Самый запрашиваемый URL (эндпоинт):

- Скрипт должен извлечь URL (например, /index.html, /api/v1/users) из тела HTTP-запроса.
- Определить и вывести один самый популярный URL и количество его вызовов. Параметры запроса (если есть, например, ?page=2) отрезать не обязательно, но это будет плюсом.

### 3. Отчет по ошибкам (Статусы 4xx и 5xx):

- Скрипт должен отфильтровать только те записи, где HTTP-статус ответа находится в диапазоне от 400 до 599.
- Вывести список таких ошибок в формате: [Дата и Время] - URL - Статус.

## 3. Архитектурные требования и ограничения

- **Память:** Файл логов может быть огромным (гигабайты). **Запрещено** считывать весь файл в память целиком через `.readlines()` или `.read()`. Чтение должно выполняться **построчно**.
- **Инструменты:** Разрешено использовать только встроенные возможности Python (стандартная библиотека). Использование `pandas` или сторонних библиотек запрещено.
- **Отказоустойчивость:** Если строка лога повреждена или имеет неверный формат, программа не должна падать с ошибкой `IndexError` или `ValueError`. Такую строку следует пропустить.

#### 4. Алгоритм разбора строки (Подсказка)

Каждая строка имеет вид: 192.168.1.1 - - [10/Jan/2025:13:45:22 +0000]  
"GET /index.html HTTP/1.1" 200 1024

Для извлечения данных используйте метод `.split()` или срезы строк.

- **IP-адрес** всегда идет первым элементом (до первого пробела).
- **Время** находится внутри квадратных скобок [...].
- **Запрос** (Метод + URL + Протокол) находится внутри двойных кавычек "...".
- **Статус** - это трехзначное число, идущее сразу после закрывающей кавычки запроса.

#### лог-файл (access.log)

Здесь симитирована реальная работа: обычные пользователи, администратор, несколько ботов-сканеров (генерирующих 404 ошибки) и падение сервера (ошибки 500).

#### Чек-лист для проверки (Ожидаемый результат)

- **Топ-5 IP-адресов:**
  1. 192.168.1.14 - 8 запросов
  2. 5.101.0.4 - 5 запросов
  3. 93.184.216.34 - 4 запроса

4. 185.220.101.5 - 3 запроса

5. 192.168.1.105 - 3 запроса

- **Самый популярный URL:** /api/v1/products (6 раз) или /index.html (6 раз) - тут получилась ничья, код должен корректно вернуть оба
- **Ошибки 4xx/5xx:** В логе ровно 8 строк с ошибками (404, 401, 403, 500). Все они должны попасть в финальный отчет с точным указанием времени.